

Sistemas Inteligentes

Tema 5.2: Redes Bayesianas

Curso 2024-25

Índice

- Probabilidad como medida de incertidumbre
- Teorema de Bayes
- Redes Bayesianas
- Información Mútua
- Inferencia mediante redes Bayesianas
 - Inferencia Exacta
 - Ejemplos
 - Inferencia aproximada
 - Muestreo directo
 - Muestreo por rechazo
 - Muestreo Gibbs
- Para saber más

Teorema de Bayes

- Sabemos que:

- $P(A|B) P(B) = P(A, B)$
- $P(B|A) P(A) = P(B, A) = P(A, B)$

- Regla de Bayes:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \alpha \cdot P(B|A)P(A)$$

- Constante de normalización $P(B)$

$$P(B) = \sum_i P(B|A_i)P(A_i)$$

Marginalización
Prob. total

- Regla de la cadena:

$$P(A, B) = P(A)P(B|A)$$

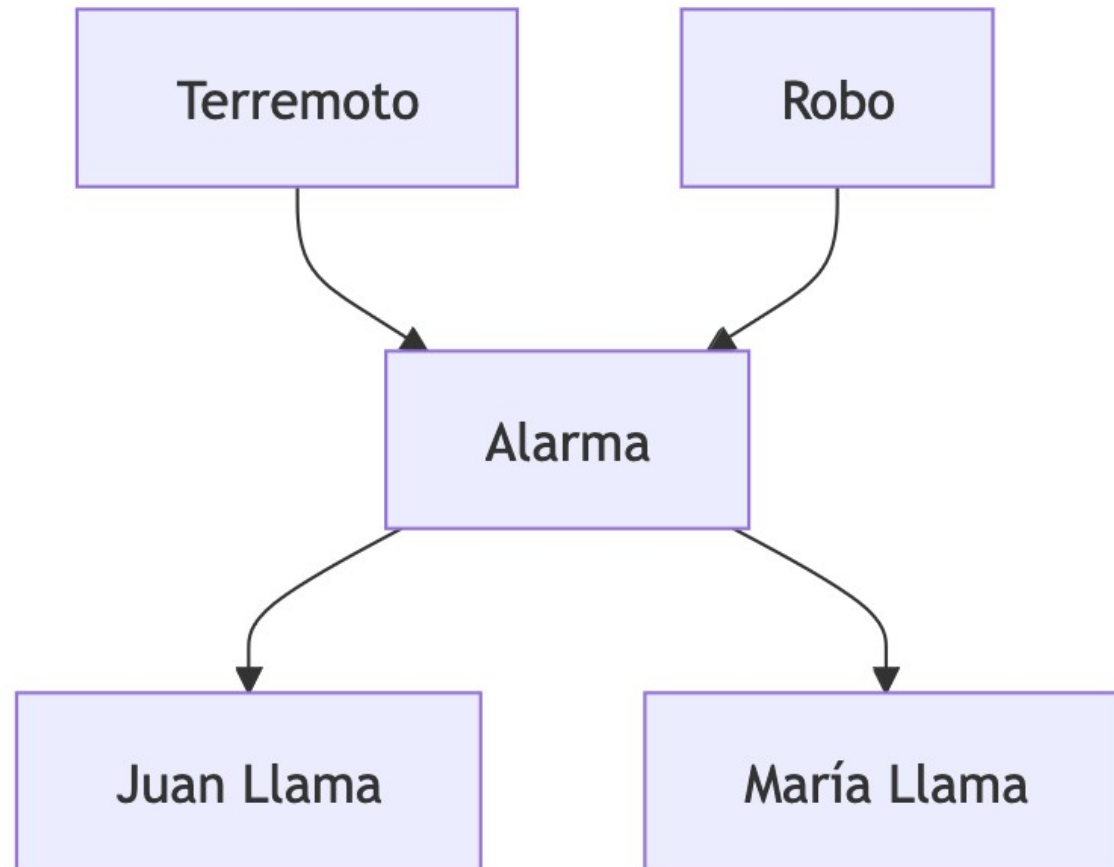
$$P(A, B, C) = P(A)P(B|A)P(C|B, A)$$

Redes Bayesianas

- Una red bayesiana es:
 - Un grafo acíclico dirigido para representar dependencias entre variables y mostrar una descripción escueta de cualquier distribución de probabilidad conjunta completa
- Esta formada por
 - Un conjunto de variables aleatorias que forman los nodos de la red. Cada nodo X tendrá adjunta una distribución $P(X|\text{Padres}(X))$
 - Un conjunto de enlaces que determinan la influencia (dependencia) entre nodos. Si X se conecta con Y se dice que X influencia a Y
- Su finalidad principal es calcular la distribución conjunta de las variables nodo


Semántica de una red

- Dada la siguiente red bayesiana...
 - ¿Qué distribución representa?




Semántica de una red

- Dada la siguiente red bayesiana...
 - $P(T,R,A,J,M) =$
 $P(T) * P(R) * P(A|T,R) * P(J|A) * P(M|A)$
 - ¿ $|P(T,R,A,J,M)|$ sin independencia condicional?
 - $2^5 = 32$
 - ¿Y con independencia condicional?
 - $2 + 2 + 2^3 + 2^2 + 2^2 = 20$



Cobertura de Markov

- Cobertura de Markov
 - Un nodo A es condicionalmente independiente de todos los nodos de la red dados:
 - Sus padres
 - Sus hijos
 - Los padres de sus hijos
 - Nos ayuda a:
 - Identificación de independencias condicionales
 - Simplificación del modelo
 - Mejorar la inferencia
 - Interpretación de relaciones
 - Reducción de complejidad



Información Mutua

Recordemos sobre la ganancia de Información:

- Mide la reducción en la entropía de la variable objetivo (clase) al conocer el valor de un atributo.
- $GI(\text{Clase}, \text{Atributo}) = E(\text{Clase}) - E(\text{Clase}|\text{Atributo})$
- **Es un caso especial de Información Mutua**, utilizado comúnmente en árboles de decisión y selección de características.

Información Mutua

Información Mutua (IM):

- Estrechamente relacionada con la Ganancia de Información
- Mide la reducción en la incertidumbre de una variable aleatoria debido al conocimiento de otra.
- Es simétrica: $I(X;Y) = I(Y;X)$
- Se define como: $I(X;Y) = E(X) - E(X|Y) = E(Y) - E(Y|X)$
- Lo usaremos para determinar que nodo es más influyente respecto a otro

$$I(X;Y) = E(X) - E(X|Y)$$

$$E(X|Y) = - \sum_{x,y} p(x,y) \log p(x|y)$$

$$I(X;Y) = \sum_{x,y} P(x,y) \cdot \log_2 \left(\frac{P(x,y)}{P(x) \cdot P(y)} \right)$$

Notar que: la entropía cond. es consistente con el tema anterior:

$$\begin{aligned}
 E(Y|X) &= \sum_i P(X = x_i) \cdot E(Y|X = x_i) \\
 &= \sum_i P(X = x_i) \cdot \left[- \sum_j P(Y = y_j|X = x_i) \log P(Y = y_j|X = x_i) \right] \\
 &= - \sum_i \sum_j P(X = x_i) \cdot P(Y = y_j|X = x_i) \log P(Y = y_j|X = x_i) \\
 &= - \sum_i \sum_j P(X = x_i, Y = y_j) \log P(Y = y_j|X = x_i) \\
 &= - \sum_{x,y} p(x,y) \log p(y|x) \\
 E(X|Y) &= - \sum_{x,y} p(x,y) \log p(x|y)
 \end{aligned}$$

Inferencia

- ¿Para que queremos la distribución conjunta?
 - A partir de la distribución conjunta podemos contestar cualquier pregunta relativa a la red...
- Varios tipos de inferencia en redes Bayesianas
 - Exacta (caso general)
 - Casos especiales (Kim&Pearl...)
 - Aproximada

Inferencia exacta

- Inferencia exacta general (funciona para todas la RR.BB.)
- Regla de inferencia general
 - (Donde B son las variables buscadas, C las conocidas y D las desconocidas)

$$P(B|C) = \alpha \cdot \sum_D P(B, D, C)$$


- Problema: mucha complejidad

Inferencia exacta: ejemplo 1

- ¿Prob. que suene la alarma si llama María?

$$P(B|C) = \alpha \cdot \sum_D P(B, D, C)$$

- $P(R, T, A, J, M) =$
 $P(R) \cdot P(T) \cdot P(A|R, T) \cdot$
 $P(J|A) \cdot P(M|A)$



Inferencia exacta: ejemplo 1

- De esta manera tenemos que:

$$P(A|M) = \alpha \cdot \sum_R \sum_T \sum_J P(R, T, A, J, M) =$$

$$= \alpha \cdot \sum_R \sum_T \sum_J P(R) \cdot P(T) \cdot P(A|R, T) \cdot P(J|A) \cdot P(M|A) =$$

$$= \alpha \cdot P(M|A) \cdot \sum_R \left(P(R) \sum_T \left(P(T) \cdot P(A|R, T) \cdot \underbrace{\sum_J P(J|A)}_1 \right) \right)$$

Inferencia exacta: ejemplo 2

- ¿ $P(R|J+,M+)$?

$$P(J|A) =$$

A	J
0	0,05
1	0,9

$$P(M|A) =$$

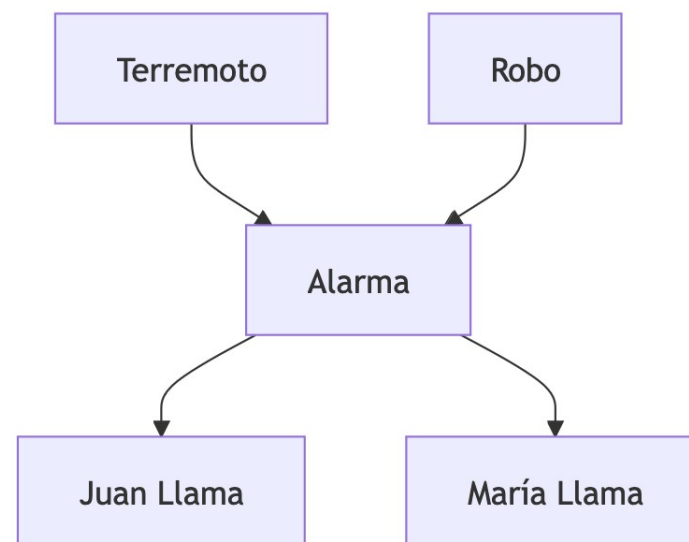
A	M
0	0,01
1	0,7

$$P(A|T,R)=$$

T	R	A
0	0	0,001
0	1	0,94
1	0	0,29
1	1	0,95

$$P(T) = 0,001$$

$$P(R) = 0,002$$



Inferencia exacta: ejemplo 2

- De esta manera tenemos que:

$$P(R|J, M) = \alpha \sum_T \sum_A P(R, T, A, J, M) =$$

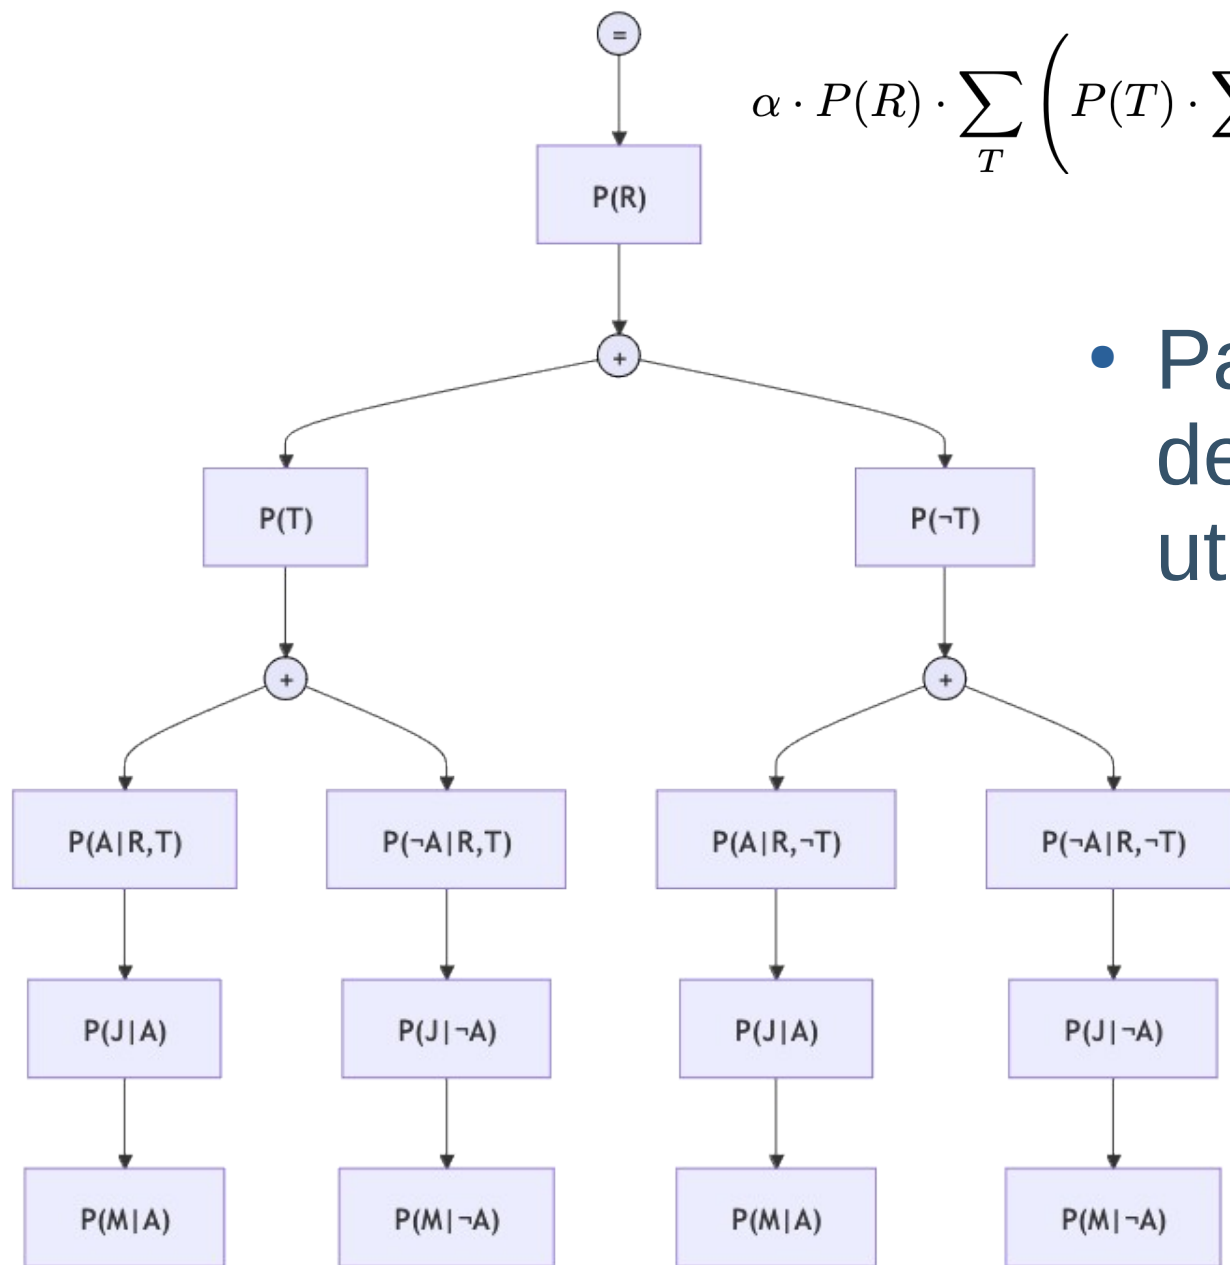
$$\alpha \sum_T \sum_A P(R) \cdot P(T) \cdot P(A|R, T) \cdot P(J|A) \cdot P(M|A) =$$

$$\alpha \cdot P(R) \cdot \sum_T \left(P(T) \cdot \sum_A (P(A|R, T) \cdot P(J|A) \cdot P(M|A)) \right)$$

Inferencia exacta: ejemplo 2

$$\alpha \cdot P(R) \cdot \sum_T \left(P(T) \cdot \sum_A (P(A|R, T) \cdot P(J|A) \cdot P(M|A)) \right)$$

- Para calcular descomponemos utilizando un árbol...



Inferencia exacta: ejemplo 2

- $P(R|J,M) = \alpha \cdot P(R) \cdot \sum_T (P(T) \cdot \sum_A (P(A|R,T) \cdot P(J|A) \cdot P(M|A)))$

- $$P(R|J,M) = \alpha \cdot P(R) \cdot [P(T) \cdot P(A|R,T) \cdot P(J|A) \cdot P(M|A) +$$

$$P(T) \cdot P(\neg A|R,T) \cdot P(J|\neg A) \cdot P(M|\neg A) +$$

$$P(\neg T) \cdot P(A|R,\neg T) \cdot P(J|A) \cdot P(M|A) +$$

$$P(\neg T) \cdot P(\neg A|R,\neg T) \cdot P(J|\neg A) \cdot P(M|\neg A)]$$

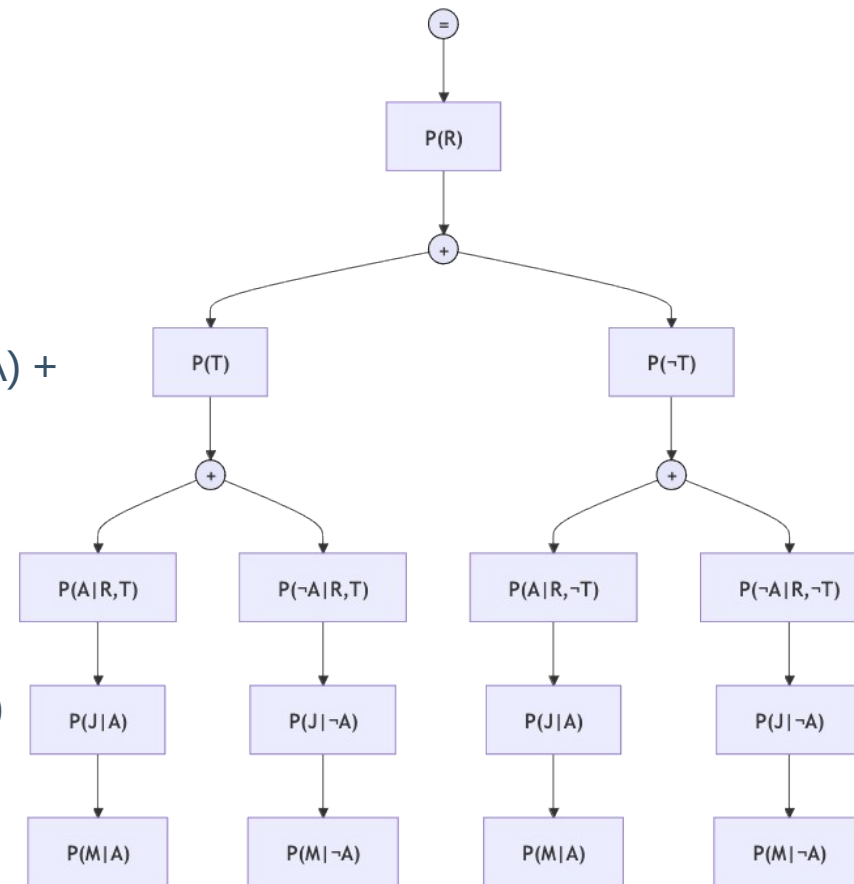
- $$P(\neg R|J,M) = \alpha \cdot P(\neg R) \cdot [P(T) \cdot P(A|\neg R,T) \cdot P(J|A) \cdot P(M|A) +$$

$$P(T) \cdot P(\neg A|\neg R,T) \cdot P(J|\neg A) \cdot P(M|\neg A) +$$

$$P(\neg T) \cdot P(A|\neg R,\neg T) \cdot P(J|A) \cdot P(M|A) +$$

$$P(\neg T) \cdot P(\neg A|\neg R,\neg T) \cdot P(J|\neg A) \cdot P(M|\neg A)]$$

- $P(R|J,M) + P(\neg R|J,M) = 1 \rightarrow \alpha = 1/(P(R|J,M) + P(\neg R|J,M))$



Inferencia exacta: ejemplo 2

- Cálculo de $P(R|J,M)$:

- $P(R|J,M) = \alpha * P(R) * [P(T) * P(A|R,T) * P(J|A) * P(M|A) + P(T) * P(\neg A|R,T) * P(J|\neg A) * P(M|\neg A) + P(\neg T) * P(A|R,\neg T) * P(J|A) * P(M|A) + P(\neg T) * P(\neg A|R,\neg T) * P(J|\neg A) * P(M|\neg A)]$
- $P(A|R,T) * P(J|A) * P(M|A) = 0,95 * 0,9 * 0,7 = 0,5985$
- $P(\neg A|R,T) * P(J|\neg A) * P(M|\neg A) = 0,05 * 0,05 * 0,01 = 0,000025$
- $P(A|R,\neg T) * P(J|A) * P(M|A) = 0,94 * 0,9 * 0,7 = 0,5922$
- $P(\neg A|R,\neg T) * P(J|\neg A) * P(M|\neg A) = (1-0,94) * 0,05 * 0,01 = 0,00003$
- $P(R|J,M) = \alpha * P(R) * [P(T) * (0,5985 + 0,000025) + P(\neg T) * (0,5922 + 0,00003)]$
 $= 0,002 * [0,001 * (0,5985 + 0,000025) + 0,999 * (0,5922 + 0,00003)]$
 $= 0,002 * [0,000598525 + 0,59223]$
 $= 0,002 * 0,592828525$
 $= 0,00118565705$

$$P(J|A) =$$

A	J
0	0,05
1	0,9

$$P(A|T,R) =$$

T	R	A
0	0	0,001
0	1	0,94
1	0	0,29
1	1	0,95

$$P(T) = 0,001$$

$$P(R) = 0,002$$

$$P(M|A) =$$


A	M
0	0,01
1	0,7

Inferencia exacta: ejemplo 2

- Cálculo de $P(R|J,M)$:
 - $$\begin{aligned}
 P(R|J,M) &= \alpha * P(R) * [P(T) * (0,5985 + 0,000025) + P(\neg T) * (0,5922 + 0,00003)] \\
 &= 0,002 * [0,001 * (0,5985 + 0,000025) + 0,999 * (0,5922 + 0,00003)] \\
 &= 0,002 * [0,000598525 + 0,59223] \\
 &= 0,002 * 0,592828525 \\
 &= 0,00118565705
 \end{aligned}$$
- Cálculo de $P(\neg R|J,M)$:
 - $$\begin{aligned}
 P(\neg R|J,M) &= \alpha * P(\neg R) * [P(T) * (0,1827 + 0,000355) + P(\neg T) * (0,00063 + 0,0004995)] \\
 &= 0,998 * [0,001 * (0,1827 + 0,000355) + 0,999 * (0,00063 + 0,0004995)] \\
 &= 0,998 * [0,000183055 + 0,00112935] \\
 &= 0,998 * 0,001312405 \\
 &= 0,00130997819
 \end{aligned}$$
- Probabilidad total
 - $P(R|J,M) + P(\neg R|J,M) = 0,00118565705 + 0,00130997819$
 - $\alpha = 1 / 0,00249563524 = 400,70003$
- Probabilidades finales:
 - $P(R|J,M) = \alpha * P(R|J,M) = 400,70003 * 0,00118565705 = 0,47509$
 - $P(\neg R|J,M) = \alpha * P(\neg R|J,M) = 400,70003 * 0,00130997819 = 0,52491$

Inferencia exacta: ejercicio

- Ejercicio: ¿ $P(J|R)$?



$$\begin{aligned}
 P(J|R) &= \sum_T \sum_A \sum_M P(R) \cdot P(T) \cdot P(A|R, T) \cdot P(J|A) \cdot P(M|A) = \\
 &= P(R) \cdot \sum_T \left(P(T) \cdot \sum_A \left(P(A|R, T) \cdot P(J|A) \cdot \sum_M P(M|A) \right) \right)
 \end{aligned}$$

Influencia entre nodos


- Usamos la información mutua para comparar entre nodos
- Ejemplo. Dada la siguiente red

A	P(A)
True	0.5
False	0.5

A	P(C = True A)	P(C = False A)
True	0.7	0.3
False	0.4	0.6

A	P(B = True A)	P(B = False A)
True	0.8	0.2
False	0.3	0.7

B	C	P(D = True B,C)	P(D = False B,C)
True	True	0.9	0.1
True	False	0.7	0.3
False	True	0.6	0.4
False	False	0.1	0.9



- ¿Qué nodo influencia más a D?

Influencia entre nodos

- Calculemos la información mutua $I(X;D)$ para $X = A, B, \text{ y } C$:

- $$I(X;Y) = \sum_{x,y} P(x,y) \cdot \log_2 \left(\frac{P(x,y)}{P(x) \cdot P(y)} \right)$$

- Primero, necesitamos calcular las probabilidades marginales:

- $$P(B+) = P(A) \cdot P(B|A) + P(A-) \cdot P(B|A-) \\ = 0.5 \cdot 0.8 + 0.5 \cdot 0.3 = 0.55;$$

- $$P(C+) = P(A) \cdot P(C|A) + P(A-) \cdot P(C|A-) \\ = 0.5 \cdot 0.7 + 0.5 \cdot 0.4 = 0.55;$$

- $$P(D+) = P(B) \cdot P(C) \cdot P(D|B,C) + \\ P(B) \cdot P(C-) \cdot P(D|B,C-) + \\ P(B-) \cdot P(C) \cdot P(D|B-,C) + \\ P(B-) \cdot P(C-) \cdot P(D|B-,C-) =$$

$$0.55 \cdot 0.55 \cdot 0.9 + \\ 0.55 \cdot 0.45 \cdot 0.7 + \\ 0.45 \cdot 0.55 \cdot 0.6 + \\ 0.45 \cdot 0.45 \cdot 0.1 \approx 0.6$$

A	P(A)
True	0.5
False	0.5

A	P(C = True A)	P(C = False A)
True	0.7	0.3
False	0.4	0.6

A	P(B = True A)	P(B = False A)
True	0.8	0.2
False	0.3	0.7

B	C	P(D = True B,C)
True	True	0.9
True	False	0.7
False	True	0.6
False	False	0.1

Influencia entre nodos

- Calculemos la información mutua $I(X;D)$ para $X = A, B$, y C :

$$I(X;Y) = \sum_{x,y} P(x,y) \cdot \log_2 \left(\frac{P(x,y)}{P(x) \cdot P(y)} \right)$$

- Primero, necesitamos calcular las probabilidades marginales:

- $$P(B+) = 0.5 * 0.8 + 0.5 * 0.3 = 0.55; P(C+) = 0.5 * 0.7 + 0.5 * 0.4 = 0.55;$$

$$P(D+) = 0.55 * 0.55 * 0.9 + 0.55 * 0.45 * 0.7 + 0.45 * 0.55 * 0.6 + 0.45 * 0.45 * 0.1 = 0.6$$

- Ahora, calculemos $I(X;D)$ para cada X :

- Para A :

- $$I(A;D) = P(A+,D+) \cdot \log_2(P(A+,D+)/P(A+)P(D+)) +$$

$$P(A+,D-) \cdot \log_2(P(A+,D-)/P(A+)P(D-)) +$$

$$P(A-,D+) \cdot \log_2(P(A-,D+)/P(A-)P(D+)) +$$

$$P(A-,D-) \cdot \log_2(P(A-,D-)/P(A-)P(D-))$$

- ¿ $P(A,D)$? =

- $$P(A,D) = P(D,A) = P(D|A)P(A)$$

$$P(D,A) = \sum_B \sum_C P(A, B, C, D)$$


$$= \sum_B \sum_C \underbrace{P(D|B,C)}_{\text{blue}} * \underbrace{P(B|A)}_{\text{red}} * \underbrace{P(C|A)}_{\text{yellow}} * P(A)$$

A	P(A)
True	0.5
False	0.5

A	P(C = True A)	P(C = False A)
True	0.7	0.3
False	0.4	0.6

A	P(B = True A)	P(B = False A)
True	0.8	0.2
False	0.3	0.7

B	C	P(D = True B,C)
True	True	0.9
True	False	0.7
False	True	0.6
False	False	0.1



Influencia entre nodos

- $P(D,A)$

$$\begin{aligned}
 P(A, D) &= \sum_B \sum_C P(A, B, C, D) \\
 &= \sum_B \sum_C P(D|B, C) * P(B|A) * P(C|A) * P(A)
 \end{aligned}$$

$$\begin{aligned}
 &= [P(D+|B+,C+)P(B+|A)P(C+|A) + \\
 &\quad P(D+|B+,C-)P(B+|A)P(C-|A) + \\
 &\quad P(D+|B-,C+)P(B-|A)P(C+|A) + \\
 &\quad P(D+|B-,C-)P(B-|A)P(C-|A)] * P(A)
 \end{aligned}$$

Para A+:

$$\begin{aligned}
 P(D+,A+) &= 0.5 * [\\
 &0.9 * 0.8 * 0.7 + // B+,C+ \\
 &0.7 * 0.8 * 0.3 + // B+,C- \\
 &0.6 * 0.2 * 0.7 + // B-,C+ \\
 &0.1 * 0.2 * 0.3] // B-,C- \\
 &= 0.5 * [0.504 + 0.168 + 0.084 + 0.006] = 0.381
 \end{aligned}$$

$$P(A+,D+) = 0,381; \quad P(A+) = P(A+,D+) + P(A+,D-)$$

$$P(A+,D-) = P(A+) - P(A+,D+) = 0.119$$

Para A-:

$$\begin{aligned}
 P(D+,A-) &= 0.5 * [\\
 &0.9 * 0.3 * 0.4 + // B+,C+ \\
 &0.7 * 0.3 * 0.6 + // B+,C- \\
 &0.6 * 0.7 * 0.4 + // B-,C+ \\
 &0.1 * 0.7 * 0.6] // B-,C- \\
 &= 0.5 * [0.108 + 0.126 + 0.168 + 0.042] = 0.22
 \end{aligned}$$

$$P(A-,D+) = 0.222; \quad P(A-) = P(A+,D+) + P(A-,D-)$$

$$P(A-,D-) = P(A-) - P(A-,D+) = 0.278$$

A	P(A)
True	0.5
False	0.5

A	P(C = True A)	P(C = False A)
True	0.7	0.3
False	0.4	0.6

A	P(B = True A)	P(B = False A)
True	0.8	0.2
False	0.3	0.7

B	C	P(D = True B,C)
True	True	0.9
True	False	0.7
False	True	0.6
False	False	0.1

Influencia entre nodos

- Calculemos la información mutua $I(X;D)$ para $X = A, B$, y C :

A	P(A)
True	0.5
False	0.5

- $$I(X;Y) = \sum_{x,y} P(x,y) \cdot \log_2 \left(\frac{P(x,y)}{P(x) \cdot P(y)} \right)$$

- Primero, necesitamos calcular las probabilidades marginales:

- $P(B+) = 0.5 * 0.8 + 0.5 * 0.3 = 0.55$; $P(C+) = 0.5 * 0.7 + 0.5 * 0.4 = 0.55$;

$$P(D+) = 0.55 * 0.55 * 0.9 + 0.55 * 0.45 * 0.7 + 0.45 * 0.55 * 0.6 + 0.45 * 0.45 * 0.1 \approx 0.6$$

- Ahora, calculemos $I(X;D)$ para cada X :

- Para A:

- $I(A;D) =$

$$\begin{aligned} &P(A+,D+) \cdot \log_2(P(A+,D+)/P(A+) \cdot P(D+)) + \\ &P(A+,D-) \cdot \log_2(P(A+,D-)/P(A+) \cdot P(D-)) + \\ &P(A-,D+) \cdot \log_2(P(A-,D+)/P(A-) \cdot P(D+)) + \\ &P(A-,D-) \cdot \log_2(P(A-,D-)/P(A-) \cdot P(D-)) \end{aligned}$$

- $P(A+) = 0.5$, $P(A-) = 0.5$

- $I(A;D) =$

$$\begin{aligned} &0.381 * \log_2(0.381/(0.5*0.6)) + 0.119 * \log_2(0.119/(0.5*0.4)) + \\ &0.222 * \log_2(0.222/(0.5*0.6)) + 0.278 * \log_2(0.278/(0.5*0.4)) \\ &\approx 0.078 \text{ bits} \end{aligned}$$

A	P(C = True A)	P(C = False A)
True	0.7	0.3
False	0.4	0.6

A	P(B = True A)	P(B = False A)
True	0.8	0.2
False	0.3	0.7

B	C	P(D = True B,C)
True	True	0.9
True	False	0.7
False	True	0.6
False	False	0.1

Influencia entre nodos

- Ahora, calculemos $I(X;D)$ para cada X :
 - Para B:**

$$P(B+,D+) = 0.55 \cdot 0.824 \approx 0.453; P(B+,D-) = 0.55 \cdot 0.176 \approx 0.097$$

$$P(B-,D+) = 0.45 \cdot 0.333 \approx 0.15; P(B-,D-) = 0.45 \cdot 0.667 \approx 0.3$$

$$I(B;D) = 0.453 \cdot \log_2(0.453/(0.55 \cdot 0.6)) +$$

$$0.097 \cdot \log_2(0.097/(0.55 \cdot 0.4)) +$$

$$0.15 \cdot \log_2(0.15/(0.45 \cdot 0.6)) +$$

$$0.3 \cdot \log_2(0.3/(0.45 \cdot 0.4))$$

$$\approx 0.186 \text{ bits}$$
 - Para C:**

$$P(C+,D+) = 0.55 \cdot 0.785 \approx 0.432; P(C+,D-) = 0.55 \cdot 0.215 \approx 0.118$$

$$P(C-,D+) = 0.45 \cdot 0.38 \approx 0.171; P(C-,D-) = 0.45 \cdot 0.62 \approx 0.279$$

$$I(C;D) = 0.432 \cdot \log_2(0.432/(0.55 \cdot 0.6)) +$$

$$0.118 \cdot \log_2(0.118/(0.55 \cdot 0.4)) +$$

$$0.171 \cdot \log_2(0.171/(0.45 \cdot 0.6)) +$$

$$0.279 \cdot \log_2(0.279/(0.45 \cdot 0.4))$$

$$\approx 0.125 \text{ bits}$$
- La información mutua más alta es para B, lo que indica que B tiene la relación más fuerte con D en términos de información compartida.

Ejercicio: diseña una red bayesi.


- Sistema de Predicción de Éxito Académico
 - Una universidad está desarrollando un sistema para predecir el éxito académico de sus estudiantes. Se han identificado los siguientes factores que podrían influir en el rendimiento de un estudiante:
 - Hábitos de estudio (buenos o malos)
 - Asistencia a clases (regular o irregular)
 - Participación en actividades extracurriculares (sí o no)
 - Nivel de estrés (alto o bajo)
 - Rendimiento académico (alto o bajo)
- Se cree que los hábitos de estudio y la asistencia a clases influyen directamente en el rendimiento académico. La participación en actividades extracurriculares puede afectar tanto al nivel de estrés como a los hábitos de estudio. El nivel de estrés, a su vez, puede influir en la asistencia a clases y en el rendimiento académico.

Ejercicio: diseña una red bayesi.

- Realiza los siguientes apartados:
 - Diseña la red
 - Calcula que distribución de prob. representa
 - Calcular la probabilidad de que un estudiante tenga un alto rendimiento académico dado que tiene buenos hábitos de estudio y baja asistencia a clases.
 - Determinar qué factor tiene mayor impacto en el rendimiento académico según el modelo creado

Ejercicio: diseña una red bayesi.

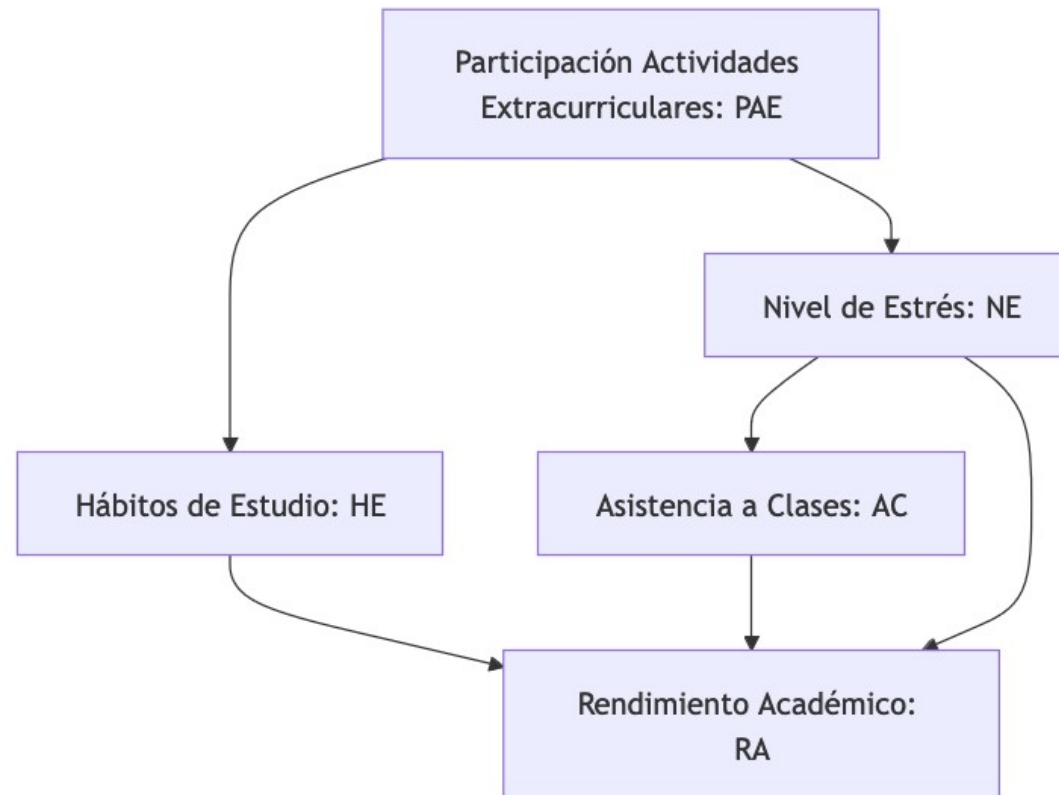
- Solución:



- ¿Qué distribución de prob. representa?

Ejercicio: diseña una red bayesi.

- Solución:



$$P(\text{PAE}, \text{HE}, \text{NE}, \text{AC}, \text{RA}) = P(\text{PAE}) \cdot P(\text{HE}|\text{PAE}) \cdot P(\text{NE}|\text{PAE}) \cdot P(\text{AC}|\text{NE}) \cdot P(\text{RA}|\text{HE}, \text{AC}, \text{NE})$$

Ejercicio: diseña una red bayesi.

- Calcular la probabilidad de que un estudiante tenga un alto rendimiento académico dado que tiene buenos hábitos de estudio y baja asistencia a clases.
- Solución:

$$P(RA|HE, AC) = \alpha \cdot P(HE, AC).$$


$$\sum_{PAE} \left(P(PAE) \cdot \sum_{NE} (P(NE|PAE) \cdot P(HE|PAE) \cdot P(AC|NE) \cdot P(RA|HE, AC, NE)) \right)$$

Ejercicio: diseña una red bayesi.

- Determinar qué factor tiene mayor impacto en el rendimiento académico según el modelo creado.
- Solución:
 - Mediante la estructura de la red:
 - Observando la estructura de la red, vemos que RA tiene tres padres directos: HE (Hábitos de Estudio), AC (Asistencia a Clases) y NE (Nivel de Estrés)
 - Sin valores numéricos específicos, podemos hacer algunas observaciones basadas en la estructura de la red:
 - HE, AC y NE probablemente tengan los mayores impactos directos en RA, ya que son sus padres inmediatos en la red.
 - Entre estos tres, NE podría tener un impacto ligeramente mayor debido a su influencia adicional a través de AC.
 - PAE, aunque no influye directamente en RA, tiene un impacto indirecto significativo a través de su influencia en HE y NE.
 - Información mutua (ganancia de la información en los árboles de decisión):
 - $I(X|Y) = E(X) - E(X|Y) = E(Y) - E(Y|X)$
 - Para cuantificar el impacto, podríamos calcular la Información Mutua (IM) entre cada variable y RA. La IM mide cuánta información proporciona una variable sobre otra. La variable con mayor IM con RA tendría el mayor impacto.

Inferencia exacta en poliárboles

- Existen algoritmos más eficientes para tipos específicos de redes
 - Modelo de Kim y Pearl
 - Método de inferencia para redes bayesianas.
 - Solo aplicable a un poliárbol.
 - No existe más de un camino entre cada pareja de nodos
 - Se basa en el paso de dos tipos de mensajes entre nodos
 - Para actualizar la credibilidad
 - Para introducir nueva evidencia
- Se puede calcular en tiempo lineal



Inferencia aproximada

- Sobre la inferencia exacta
 - Redes con conexión múltiple son intratables utilizando inferencia exacta
 - Complejidad NP-hard en el caso general
- Inferencia utilizando algoritmos de muestreo aleatorio (Monte Carlo)
 - Existen varios algoritmos
 - Muestreo directo
 - Muestreo por rechazo

Inferencia aproximada

- Muestreo directo

Algoritmo MuestreoDirecto(rb)

Entrada: rb : red Bayesiana

Salida: Un evento extraído de rb

$X \leftarrow \langle \text{vector de sucesos con } n \text{ elementos} \rangle$

for cada variable X_i en X_1, \dots, X_n **do**

$X_i \leftarrow$ Obtener una muestra aleatoria de $P(X_i | \text{Padres}(X_i))$

Devolver X

Para responder cualquier pregunta de la red

- Obtener un vector de eventos $X[]$
- Contar apariciones en $X[]$ de las evidencias
- Dividir por suficientesMuestras

Inferencia aproximada

Ejemplo de muestreo de una red mediante muestreo directo

$$P(T) = 0,001; P(R) = 0,002$$

$P(A|T,R)=$

T	R	A
0	0	0,001
0	1	0,29
1	0	0,94
1	1	0,95


$P(J|A) =$

A	J
0	0,05
1	0,9

$P(M|A)=$

A	J
0	0,01
1	0,7

1. Muestreo a partir de $P(\text{Terremoto}) = \langle 0,001 \ 0,999 \rangle$.
supongamos (s.) que devuelve *falso*
2. Muestreo($P(\text{Robo})$) s. devuelve *falso*
3. Muestreo($P(\text{Alarma} | \langle \text{Robo}=\text{falso}, \text{Terremoto}=\text{falso} \rangle)$)
s. devuelve *cierto*
4. Muestreo($P(\text{Juan} | \langle A=\text{cierto} \rangle)$)
s. Devuelve *cierto*
5. Muestreo($P(\text{Maria} | \langle A=\text{cierto} \rangle)$)
s. Devuelve *falso*
6. $X_i = \langle \text{falso}, \text{falso}, \text{cierto}, \text{cierto}, \text{falso} \rangle$



Inferencia aproximada

Ejemplo de uso

¿ $P(R|J,M)$?

$P(T) = 0,001$;

$P(R) = 0,002$

$P(A|T,R)=$


T	R	A
0	0	0,001
0	1	0,29
1	0	0,94
1	1	0,95

$P(J|A) =$

A	J
0	0,05
1	0,9

$P(M|A)=$

A	J
0	0,01
1	0,7



1. Para obtener $P(R|J,M)$
2. $C = \text{Contar } X[]$ que cumpla este patrón
 $X = \langle ?, \text{cierto}, ?, \text{cierto}, \text{cierto} \rangle$
3. Devolver $C/\text{numeroDeMuestras}$

Inferencia aproximada

- ¿Problemas del muestreo directo?
- Otros tipos de muestreo aleatorio
 - Muestreo por rechazo
 - Gibbs sampling

Muestreo por rechazo

Algoritmo MuestreoPorRechazo(B, c, rb)

Entradas:

B : variable buscada (pregunta)

c : valores observados de las variables conocidas C

rb : red bayesiana

Variables locales:

N : vector de recuento para cada valor de B , inicialmente 0

for $j = 1$ hasta numMuestras **do**

$x \leftarrow$ MuestreoDirecto(rb)

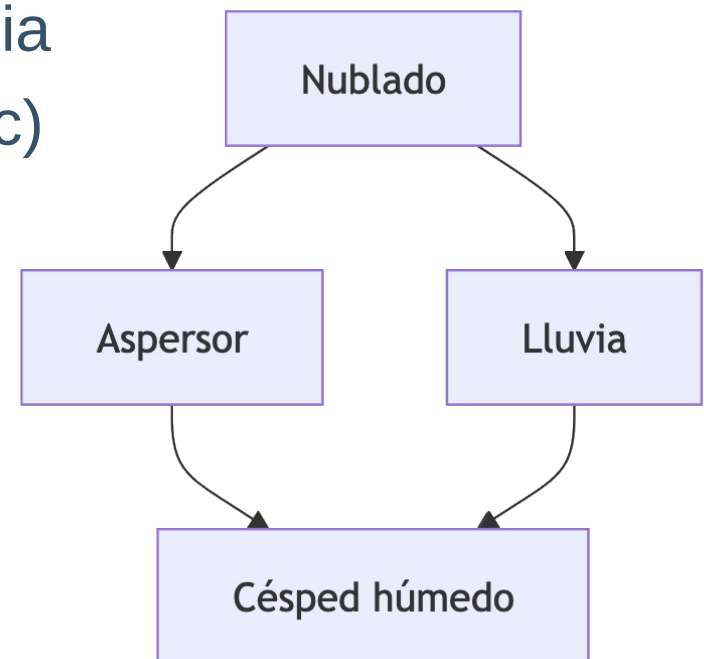
if x es consistente con la evidencia c **then**

$N[y] \leftarrow N[y] + 1$, donde y es el valor de B en x

Devolver Normalizar(N)

Muestreo por rechazo

- Ejemplo:
 - Queremos estimar $P(\text{Lluvia}|\text{Aspersor}=\text{cierto})$
 - Extraemos 100 muestras. Este proceso se haría de manera incremental por muestra:
 - Si 73 tienen el aspersor apagado \rightarrow se ignoran.
 - Si 27 que coinciden con la evidencia (x es consistente con la evidencia c)
 - En 8 Lluvia = cierto ($N[\text{cierto}]++$)
 - En 19 Lluvia es falso ($N[\text{falso}]++$)
 - $P(\text{Lluvia}|\text{Aspersor}=\text{cierto}) = \text{Normalizar}(<8,19>) = <0.296,0.704>$



Bibliografía

- Árboles:
 - Escolano et al. Inteligencia Artificial. Thomson-Paraninfo 2003. Capítulo 4.
 - Mitchel, Machine Learning. McGraw Hill, Computer Science Series. 1997
 - Cover, Thomas, Information Theory. Wiley & Sons, New York 1991
- Redes Bayesianas:
 - Stuart Russell, Peter Norving. “Inteligencia Artificial. Un enfoque Moderno” Ed. Pearson. Prentice Hall.